



华中科技大学学报(自然科学版)

Journal of Huazhong University of Science and Technology(Natural Science Edition)

ISSN 1671-4512,CN 42-1658/N

《华中科技大学学报(自然科学版)》网络首发论文

题目：基于大语言模型的服务机器人任务规划方法
作者：李世其，郑旋烨，刘裔斌，周雨玫
DOI：10.13245/j.hust.240258
收稿日期：2024-04-26
网络首发日期：2026-03-13
引用格式：李世其，郑旋烨，刘裔斌，周雨玫. 基于大语言模型的服务机器人任务规划方法[J/OL]. 华中科技大学学报(自然科学版).
<https://doi.org/10.13245/j.hust.240258>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13245/j.hust.240258

基于大语言模型的服务机器人任务规划方法

李世其 郑旋烨 刘裔斌 周雨玫

(华中科技大学机械科学与工程学院, 湖北 武汉 430074)

摘要 为解决服务机器人工作过程中理解能力不足、规划能力有限, 无法适应服务场景需求的问题, 提出一种基于大语言模型的服务机器人任务规划方法。首先基于大语言模型和视觉语言模型构建机器人理解和感知模块, 提高机器人推理和规划能力。其次, 设计了机器人 Agent 框架, 把机器人感知、运动等模块封装为工具, 实现大语言模型对服务机器人的自主控制。再次, 搭建实验场景与平台, 采用低秩适应(LoRA)方法对 ChatGLM3 模型进行微调, 传入服务场景相关信息, 增强其场景适应性。最后实验结果表明, 通过此方法服务机器人可根据用户指令与环境信息进行自主规划, 基于 ChatGLM3 微调模型和 GPT-3.5-Turbo 模型的控制系统的任务成功率分别达到了 81% 与 84%。

关键词 大语言模型; 视觉语言模型; 服务机器人; Agent; 任务规划

中图分类号 TP242.6 **文献标志码** A

Task planning method of service robot based on large language model

LI Shiqi ZHENG Xuanye LIU Yibin ZHOU Yumei

(School of Mechanical Science and Engineering, Huazhong University of Science and Technology, Wuhan 430074, China)

Abstract To address the problems of insufficient comprehension capability and limited planning capability of service robots during operation, which render them unable to meet the requirements of service scenarios, a task planning method for service robots based on a large language model is proposed. Firstly, the robot's comprehension and perception modules are constructed based on the large language model and vision-language model to enhance the robot's reasoning and planning capabilities. Secondly, a robot Agent framework is designed, where modules such as robot perception and motion are encapsulated as tools to realize the autonomous control of the service robot by the large language model. Thirdly, experimental scenarios and platforms are established, and the Low-Rank Adaptation (LoRA) method is adopted to fine-tune the ChatGLM3 model; relevant information about service scenarios is fed into the model to enhance its scenario adaptability. Finally, experimental results show that the service robot can perform autonomous planning according to user instructions and environmental information through this method, and the task success rates of the control systems based on the fine-tuned ChatGLM3 model and the GPT-3.5-Turbo model reach 81% and 84% respectively.

Key words large language model; vision-language model; service robot; Agent; task planning

随着人工智能技术的发展和人口老龄化的加剧, 服务机器人相关产业市值持续增长。但在实际应用中, 目前服务机器人对于用户指令的理解能力有限, 对于信息繁杂的服务场景感知能力不足, 难以应对多样性的任务需求。因此, 提高机器人对多样化的用户指令、场景信息的处理能力能显著改善交互体

验, 具有重要意义与应用价值。

在指令文本理解及任务规划方面, 自然语言处理相关研究已有了大量成果。文献^[1]通过构建专家系统, 在服务机器人任务规划中实现了不完整信息推理。文献^[2]为提高机器人对家庭环境的语义认知能力, 提出了一种基于卷积神经网络的环境语义认

收稿日期 2024-04-26.

作者简介 李世其(1965—), 男, 教授, E-mail: sqli@hust.edu.cn.

基金项目 广东省机器人定位导航技术企业重点实验室项目(2020B121202011).

知模型。文献^[3]提出了一种基于服务策略的文本生成机制,用于辅助生成机器人动作序列。总体来看,基于机器学习和统计的理解与规划方法已取得了一定成效,但还无法完全适应复杂多变的真实环境。而近年来基于 Transformer 结构的语言模型发展迅速,以 OpenAI 公司推出的 ChatGPT 为代表,大语言模型(LLM)展现出的优越能力受到广泛关注,同类模型如 Llama 2^[4]、Gemini^[5]等也快速推出。在应用方面,文献^[6]提出了名为 RobotGPT 的机器人操作决策框架,在多种测试中对框架的有效性进行了验证。文献^[7]针对舆情情感分析问题,提出了一种融合大语言模型知识的对比提示情感分析方法。文献^[8]提出了一种基于 LLMs 的任务自主规划处理框架,实现了对于复杂任务的有效处理。

而在此基础上,为了将大语言模型体现的强大的通用能力拓展至其他信息领域,以视觉语言模型(VLM)为代表的多模态模型也成为研究热点之一。以 CLIP^[9]为代表的模型通过联合训练文本和图像编码器,实现了视觉与文本两种模态的桥接。而 GPT-4V^[10]模型则展现了大语言模型的逻辑推理能力与视觉模型的图像感知能力充分结合的优异性能。RT-2^[11]等项目则进一步实现了多模态模型对于机器人的动作控制。

综上所述,大语言模型和视觉语言模型在文本和图像感知理解方面体现出较高的通用性,同时具有充分的常识储备和良好的逻辑推理能力。而针对服务机器人工作需求,本研究提出一种基于大语言模型的服务机器人任务规划方法。方法采用微调后的 ChatGLM3、GPT-3.5-Turbo 模型作为推理核心,进行指令意图理解和总体任务规划,并采用 CogAgent^[12]视觉语言模型作为高层视觉语义感知模块,进行环境分析与推理。其次,使用 YOLO-World^[13]开放词汇目标检测模型,实现对陌生物体的实时检测。再次,将以上模型和机器人各功能控制模块接入 Agent 框架,进而实现从机器人接收用户指令,到生成总体任务规划,并逐步迭代生成行动规划,选择合适工具执行各类任务的整体流程,并实验验证了方法的有效性。

1 机器人语义理解及环境感知原理

服务机器人工作时,为合理规划任务,需理解用户指令意图、感知环境语义信息。而服务场景中用户需求多样、环境信息复杂,传统算法无法满足

实际需要,因此引入大语言模型、视觉语言模型和 YOLO-World 模型提升其理解和感知能力。

1.1 大语言模型及微调原理

GPT-3.5-Turbo 由 OpenAI 推出,有较强语言生成和理解能力,但仅支持 API 调用,无法本地部署。而 ChatGLM3 是由智谱 AI 和清华联合发布的开源模型,采用 Decoder-Only 架构,其优点是计算资源需求低,可在消费级 GPU 上部署。

上述大语言模型较传统算法对自然语言指令的理解能力提升明显,但在特定领域存在局限。因此,需基于服务场景构建数据集,通过提示词工程和微调调整大语言模型,以适配服务场景。

而在大语言模型微调方面,随着模型规模的快速增长,目前常采用参数高效微调方法对模型进行调整,其只需调整少量模型参数即可改变模型性能,从而可适配各类下游应用,代表方法有 P-Tuning、P-Tuning v2、LoRA 等。其中,LoRA 方法与其他方法相比,优点在于可灵活在多个下游任务之间切换。

1.2 CogAgent 视觉语言模型

CogAgent 作为开源视觉语言模型,拥有 1.1×10^{10} 的视觉参数和 7×10^9 的语言参数,支持 120×120 分辨率的图像输入,能执行视觉问答等多项任务。

通过引入 CogAgent 视觉语言模型,机器人可实现对于复杂服务场景的语义信息提取,进行深度图像理解,从而有助于进行任务理解与规划。

1.3 YOLO-World 开放词汇目标检测模型

CogAgent 等视觉语言模型虽然实现了对于图像信息的深度理解,但机器人在执行物体搜寻、抓取等具体任务时,对于感知模块的实时性有较高要求,视觉语言模型由于计算负担所限无法满足。针对此类问题,引入 YOLO-World 开放词汇目标检测模型。

与传统的 YOLO 系列模型相比,YOLO-World 能通过文本提示词输入,实现对于陌生对象的检测识别。而与 Grounding DINO^[14]等已有的开放词汇目标检测模型相比,YOLO-World 算法的实时性有显著提高,使其具有更高的实际应用价值。而通过与大语言模型结合,可由大语言模型生成检测任务所需的提示词来控制 YOLO-World 进行实时检测。

2 服务机器人 LLM 控制系统

在服务场景中，机器人需应对场景、目标、复杂度各异的任务，其规划与控制流程无法预设，需结合用户需求、场景数据及自身功能自主规划执行，为此选择引入大语言模型等模块。而为了在实际应

用中充分发挥大语言模型、视觉语言模型、机器人功能组件等多个模块的效能，改善交互体验，本研究设计了一套服务机器人 LLM 控制系统，具体如图 1 所示。




图1 服务机器人 LLM 控制系统

该系统以经 LoRA 微调后的 ChatGLM3 或设定提示词工程的 GPT-3.5-Turbo 为推理核心，以 CogAgent 和 YOLO-World 为机器人视觉感知模块。系统将机器人语音交互模块、视觉感知模块、运动控制模块共同接入推理核心，大语言模型负责进行任务规划和指令生成，语音交互模块负责在用户和大语言模型之间传递信息，视觉感知模块负责接收指令进行环境感知并反馈感知信息，运动控制模块负责接收指令控制机器人执行具体动作并反馈运动状态信息。

2.1 基于 LangChain 的 Agent 框架

基于上述系统整体设计，需要将机器人多个功能模块控制权限给予大语言模型，并且大语言模型需要基于用户需求生成任务规划，自主选择功能模块尝试实现任务，并能基于各模块的反馈信息构成的上下文进行策略调整。为此，本研究引入 LangChain 以实现上述功能。

LangChain 是一个大语言模型程序开发框架，旨在辅助开发者构建端到端的大语言模型程序，其提供了一套工具接口，可标准化管理多个组件与大语言模型的交互。

具体而言，本研究基于 LangChain 构建了如图 2 所示的 Agent 框架，其中实线代表归属关系，虚线代表依赖关系。框架将 ChatGLM3 或 GPT-3.5 Turbo 作为 Agent 推理核心，设定记忆区块，撰写思维链(CoT^[15])、ReAct^[16]提示模板，将 CogVLM、YOLO-World、语音交互模块、运动控制模块的各个接口定义为工具格式。




图2 Agent 框架

2.2 Agent 记忆模块设定

记忆模块在 Agent 框架中起着重要作用，用于储存 Agent 行动信息，主要包括思考内容、环境感知信息、操作记录以及人机交互信息。一般而言，Agent 记忆模块可分为短期记忆和长期记忆。短期记忆主要储存有关 Agent 当前任务的思考和行动，从而令 Agent 具有判断当前任务推进情况和机器人自身状态的能力。长期记忆主要储存过去长时间段的行动记录，从而提高 Agent 对于当前环境以及相似任务的理解能力。

在实际应用中，短期记忆一般采用列表格式实现，并随着 Agent 推理和行动的进行逐步添加。而在任务完成后，短期记忆将被压缩，从完整记录中提取出任务需求、工具类别等关键信息，并作为单条记录储存至长期记忆文档中。在进行新的任务时，将基于 Faiss 向量数据库实现从长期记忆文档中搜索与本次任务需求相似性较高的记录条目，作为参考信息添加至提示词中，从而辅助 Agent 进行推理规划。

2.3 大语言模型推理规划流程设定

在基于 LangChain 构建了 Agent 框架后，还需要通过提示词工程对于大语言模型的推理规划流程进行进一步设定。

首先,引入了 Few-Shot-CoT 提示模板,通过提供少量任务的步骤内容作为示例,引导大语言模型采用 CoT 形式进行推理,即从<input→output>转为<input→reasoning chain→output>,这将增强大语言模型的推理能力和指令遵循能力。

其次,为了进一步提高大语言模型对于各类复杂情况的处理能力,设定了 ReAct 提示模板。基于此模板,大语言模型能将推理和动作紧密结合,并提高了运行结果的可解释性和可信度。

2.4 工具封装及提示词设定

基于上述总体框架,将机器人的各个功能模块拆分为工具进行封装,以便大语言模型进行任务规划和调用。首先,将 CogAgent 和 YOLO-World 封装为视觉感知工具。其次,将基于讯飞开放平台 API 的语音识别模块和基于 Google Text-to-Speech 库的语音合成模块封装为语音交互工具。再次,将基于 Gmapping 算法和 move_base 功能包实现的机器人定位导航脚本封装为导航工具。最后将机器人运动控制接口封装为运动控制工具。具体工具描述信息如表 1 所示。

表 1 工具描述信息

工具种类	用途	传入参数
CogAgent Tool	进行图像理解	问题文本
YOLO-World Tool	进行目标检测	目标种类
Speech Recognition Tool	进行语音识别	语言种类
Speech Synthesis Tool	进行语音合成	源文本
Navigation Tool	进行室内导航	目的地
Movement Tool	控制底盘移动	方向及距离

在工具调用方面,大量工具需要大语言模型自主生成相关参数进行控制,如 YOLO-World 模型所需的检测目标种类文本、导航工具所需的目的地等,而这可通过工具提示词描述来实现。提示词主要内容包括:功能描述、输入参数格式、输出参数格式、注意事项。通过标准化的提示词描述,大语言模型能快速掌握各类工具模块的调用方法,降低了开发成本。

3 实验验证

3.1 实验场景及平台搭建

为验证本研究提出的任务规划方法的有效性,需通过实际实验开展测试,为此搭建了一套深度学习平台,关键参数配置如下: GPU 为 NVIDIA

GeForce RTX 4090,操作系统为 Ubuntu 20.04,深度学习框架为 PyTorch 2.1.0。

同时,搭建了服务机器人实验平台,基于 ROS 实现机器人控制。服务机器人全身自由度为 15,采用全向轮底盘,最大速度可达 1 m/s,并搭载了 RGBD 相机、激光雷达等多种传感器。其次搭建了如图 3 所示的图书馆接待服务场景。




图 3 图书馆接待服务场景

3.2 数据集制作

为了向 ChatGLM3 补充图书馆接待服务场景背景信息并规范化推理流程,需要对预训练模型进行 LoRA 微调。由此制作了相关数据集,设定了 tools、role、content 等字段,具体格式如表 2 所示。数据集内填充了大量带有工具描述、背景信息的示例,包含场景内地点名、物品所在位置等信息。

表 2 微调数据集格式

字段类型	填充内容
tools	可用工具的具体描述
conversations	整体对话内容
role	对话角色,包括 system、user、assistant、tool
content	对应 role 的对话文本、提示词
parameters	工具调用所需参数
observation	工具调用后的反馈信息

为了解决微调时模型对话能力与工具调用功能之间的冲突,本研究采用多 Agent 框架的思想,分别制作了总体规划能力微调数据集和任务执行能力微调数据集各 2 000 条,以 8:1:1 的比例划分为训练集、验证集、测试集。总体规划能力微调数据集内容包括用户需求和总体任务规划。而任务执行能力微调数据集则涵盖基于输入的总体任务规划文本进行多步工具调用的过程,两种数据集的内容共同构成完整任务流程。基于两种数据集分别对原始模型进行微调,可获得两个能力各有侧重的微调模型,用以分别完成规划和执行工作。

而具体到数据集内容,其包含路径引导、物品搜寻、场景信息介绍、运动指令执行等多种任务。为便于分析,本研究以难易度 *d* 对各种任务进行划

分，其数值基于任务步骤 s 和调用的工具种类 k 以及难度系数 α 和 β 计算得出，具体公式如下：

$$d = \alpha \cdot s \cdot \beta \cdot k \quad (1)$$

$$\alpha = \begin{cases} 1, & 0 < s \leq 3 \\ 1.25, & s > 3 \end{cases} \quad (2)$$

$$\beta = \begin{cases} 1, & 0 < k \leq 2 \\ 1.25, & 2 < k \leq 4 \\ 1.5, & 4 < k \leq 6 \end{cases} \quad (3)$$

由此，对图书馆接待服务场景中各类机器人任务进行难度值计算，示例如表 3 所示。

表 3 任务难度计算示例

用户输入	s	k	d
前进 1 米	1	1	1
我想还书	4	3	18.75
现在书架上有《机器人学》吗？	6	4	37.50
检查一下，所有房间的灯都关了吗？	10	4	62.50

在难易度数值计算基础上，依次将 d 值处于 0 至 20、20 至 40、40 以上的任务分为简单、正常、困难三等，在数据集中的分布如表 4 所示。

表 4 不同难度任务占比

任务难度	数据集中占比/%
简单($0 < d \leq 20$)	30
正常($20 < d \leq 40$)	40
难度($d > 40$)	30

3.3 实验结果与分析

基于上述数据集，采用 LoRA 方法对 ChatGLM3 原始模型进行微调，最大训练步数设定为 2 000，学

习率为 5×10^{-5} ，batch size 设定为 4。微调完成后，将 Chatglm3 原始模型、Chatglm3 微调模型、

GPT-3.5-Turbo API 分别部署进行测试。测试任务包括运动指令执行、物品搜寻、语音交互等基础任务以及结合多种基础任务构成的复合任务，共有简单、正常、困难任务各 100 项。通过比较模型训练前后的总体任务规划成功率(R_a)、工具调用成功率(R_b)、任务成功率(R_c)、平均任务耗时(T)来评估模型能力。其中，总体任务规划成功率表示大语言模型接收用户输入后，进行理解成功生成正确的总体任务规划的比率。工具调用成功率表示大语言模型基于规划内容成功选择合理工具执行任务的比率。任务成功率则表示机器人最终成功完成任务的比率。平均任务耗时则表示所有成功任务的平均耗时。具体计算公式如下：

$$R_a = \frac{n_a}{n_{all}} \quad (4)$$

$$R_b = \frac{n_b}{n_{all}} \quad (5)$$

$$R_c = \frac{n_c}{n_{all}} \quad (6)$$

$$T = \frac{\sum_{i=1}^{n_c} t_i}{n_c} \quad (7)$$

其中， n_a 、 n_b 、 n_c 分别代表实现任务规划、工具调用、最终目标的任务数， n_{all} 代表总任务数， t_i 代表单次任务耗时。实验数据如表 5 所示。

表 5 服务场景实验测试结果

任务 难度	ChatGLM3 原始模型				ChatGLM3 微调模型				GPT-3.5-Turbo			
	R_a	R_b	R_c	T/s	R_a	R_b	R_c	T/s	R_a	R_b	R_c	T/s
简单	0.95	0.92	0.90	30.60	1.00	1.00	0.95	28.20	1.00	0.97	0.92	39.40
正常	0.84	0.73	0.65	61.20	0.95	0.89	0.79	70.30	0.93	0.90	0.85	86.40
困难	0.70	0.52	0.30	97.40	0.90	0.82	0.68	105.80	0.86	0.83	0.76	133.60
均值	0.83	0.72	0.62	63.07	0.95	0.90	0.81	68.10	0.93	0.90	0.84	86.47

从表 5 可以看出，微调后的 ChatGLM3 模型较原始模型的测试表现有所上升，规划能力、工具调用能力都明显提高，任务成功率达到了 81%，说明微调训练改善了 ChatGLM3 模型对于用户指令、环境信息、工具特性的理解程度，提高了模型对于总体任务规划的指令遵循能力。而 GPT-3.5-Turbo 模型因其整体参数规模更大，基础性能更强，在仅使用提示词的情况下，任务成功率达到了 84%，但平

均任务耗时相对较高。考虑到不同任务之间复杂度不同、模型在面对同一任务时生成的规划内容及执行步骤可能不同，为了深入分析模型推理时的表现，引入平均步骤效率(E)与平均单步推理耗时(F)指标。平均步骤效率为模型完成各类任务所采用的步骤数与理论步骤数之比的平均值，平均单步推理耗时表示去除机器人执行动作时间后，模型进行单步推理的平均耗时。具体计算公式如下：

$$E = \frac{\sum_{i=1}^{n_c} \frac{s_i}{p_i}}{n_c} \quad (8)$$

$$F = \frac{\sum_{i=1}^{n_c} \frac{u_i}{s_i}}{n_c} \quad (9)$$

其中, s_i 为单次任务实际步骤数, p_i 为单次任务理论步骤数, u_i 为单次任务推理总时间。实验测量数据如表 6 所示。

表 6 平均步骤效率与平均单步推理耗时测量结果

模型种类	E	F/s
ChatGLM3 原始模型	1.16	2.13
ChatGLM3 微调模型	1.08	2.16
GPT-3.5-Turbo	1.14	6.04

从表 6 可以看出, 在平均步骤效率方面, ChatGLM3 原始模型的测试值最高, 代表其在任务规划和执行过程中出现了较多的冗余步骤。而

ChatGLM3 微调模型则因对于工具的调用方法和场景信息有更深度的理解, 平均步骤效率明显上升, 两者的平均单步推理耗时也较为相近。而 GPT-3.5-Turbo 基于提示词内容, 平均步骤效率也控制在合理范围, 但由于 API 访问造成的延时导致耗时较长。

综合来看, ChatGLM3 这类参数规模较小的模型与以 GPT-3.5-Turbo 为代表的企业级模型相比, 其原生推理能力和理解能力还存在一定差距, 但其优点在于可进行低成本的本地部署与微调来改善模型能力, 并且推理耗时较低。而基于 API 访问的企业级模型则原生能力较强, 但受限于用户隐私安全、成本等问题, 在定制化应用方面有所不足, 并且耗时较长。

为了进一步说明总体系统运行流程, 图 4 以一次任务为例进行分析。场景信息如图 3 所示, 其中有两名用户和多种物品可与机器人进行交互。




图 4 任务流程示例

首先由用户输入自然语言指令, LLM 基于用户输入和场景背景知识, 生成了符合 CoT 模板的任务规划内容。随后基于规划内容进行 ReAct 推理和行动, 每次行动调用的工具和反馈都将记录, 以规划下一步行动。LLM 在此过程中, 逐步调用了导航模块、CogAgent 模型、YOLO-World 模型、语音合成模块等工具, 实现了机器人运动控制以及人机交互

流程。最后当 LLM 判断任务已完成时, 流程停止。

从实验流程可看出, 此种基于大语言模型的服务机器人任务规划方法实现了对于用户需求文本的深度理解和总体任务规划以及单步行为规划的合理生成, 基于 LangChain 构建的 Agent 框架实现了大语言模型对于机器人各功能模块的灵活调用, 整体驱动服务机器人完成了用户发出的自然语言任务,

证明了该方法的有效性。与传统任务流程固定的控制方法相比，机器人具有了对于各类未知情况的应对能力，体现了方法的优越性。

4 结语

本研究针对服务机器人工作中理解能力不足，规划能力有限，无法适应多样化服务任务的问题，提出了一种基于大语言模型的服务机器人任务规划方法。首先基于大语言模型、视觉语言模型构建了机器人理解与感知模块，提高其推理和规划能力。其次设计了基于 LangChain 的 Agent 框架，设定了 CoT、ReAct 提示模板，并将 CogAgent、YOLO-World 模型以及机器人控制模块等组件封装为工具以备大语言模型调用。再次，搭建了实验场景与平台，采用 LoRA 方法对 ChatGLM3 模型进行微调，导入服务场景背景信息以提高其适应性及规划能力。最后实验结果表明，通过此方法服务机器人可对用户指令与环境信息进行深度理解，并自主生成规划内容，基于 ChatGLM3 微调模型和 GPT-3.5-Turbo 模型的控制系统的任务成功率分别达到了 81%与 84%，验证了此任务规划方法的有效性。

参 考 文 献

- [1]SAVAGE J, ROSENBLUETH D A, MATAMOROS M, et al. Semantic reasoning in service robots using expert systems[J]. *Robotics and Autonomous Systems*, 2019, 114: 77-92.
- [2]田国会, 王晓静, 张营. 一种家庭服务机器人的环境语义认知机制[J]. *华中科技大学学报(自然科学版)*, 2018, 46(12): 18-23.
- [3]崔永成, 田国会, 周昭旭, 等. 智能空间下面向动作序列生成的服务机器人指令解析方法[J]. *机器人*, 2024, 46(1): 1-15.
- [4]TOUVRON H, MARTIN L, STONE K, et al. Llama 2: open foundation and fine-tuned chat models[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2307.09288>.
- [5]ANIL R, BORGEAUD S, ALAYRAC J B, et al. Gemini: a family of highly capable multimodal models[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2312.11805>.
- [6]JIN Y, LI D, YONG A, et al. RobotGPT: robot manipulation learning from ChatGPT[J]. *IEEE Robotics and Automation Letters*, 2024, 9(3): 2543-2550.
- [7]严豫, 杨笛, 尹德春. 融合大语言模型知识的对比提示情感分析方法[J]. *情报杂志*, 2023, 42(11): 126-134.
- [8]秦龙, 武万森, 刘丹, 等. 基于大语言模型的复杂任务自主规划处理框架[J]. *自动化学报*, 2024, 50(4): 862-872.
- [9]RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]// *Proc of International Conference on Machine Learning*, New York: PMLR, 2021: 8748-8763.
- [10]YANG Z, LI L, LIN K, et al. The dawn of LMMs: preliminary explorations with GPT-4V(ision)[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2309.17421>.
- [11]BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: vision-language-action models transfer web knowledge to robotic control[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2307.15818>.
- [12]HONG W, WANG W, LV Q, et al. CogAgent: a visual language model for GUI agents[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2312.08914>.
- [13]CHENG T, SONG L, GE Y, et al. YOLO-World: real-time open-vocabulary object detection[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2401.17270>.
- [14]LIU S, ZENG Z, REN T, et al. Grounding DINO: marrying dino with grounded pre-training for open-set object detection[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2303.05499>.
- [15]WEI J, WANG X, SCHUURMANS D, et al. Chain-of-Thought prompting elicits reasoning in large language models[J]. *Advances in Neural Information Processing Systems*, 2022, 35: 24824-24837.
- [16]YAO S, ZHAO J, YU D, et al. ReAct: synergizing reasoning and acting in language models[EB/OL]. [2024-04-24]. <https://arxiv.org/abs/2210.03629>.